Rust 2019

compscicenter.ru

aleksey.kladov@gmail.com

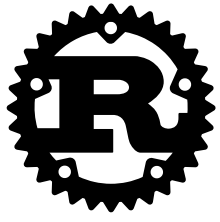

Лекция 11
unsafe

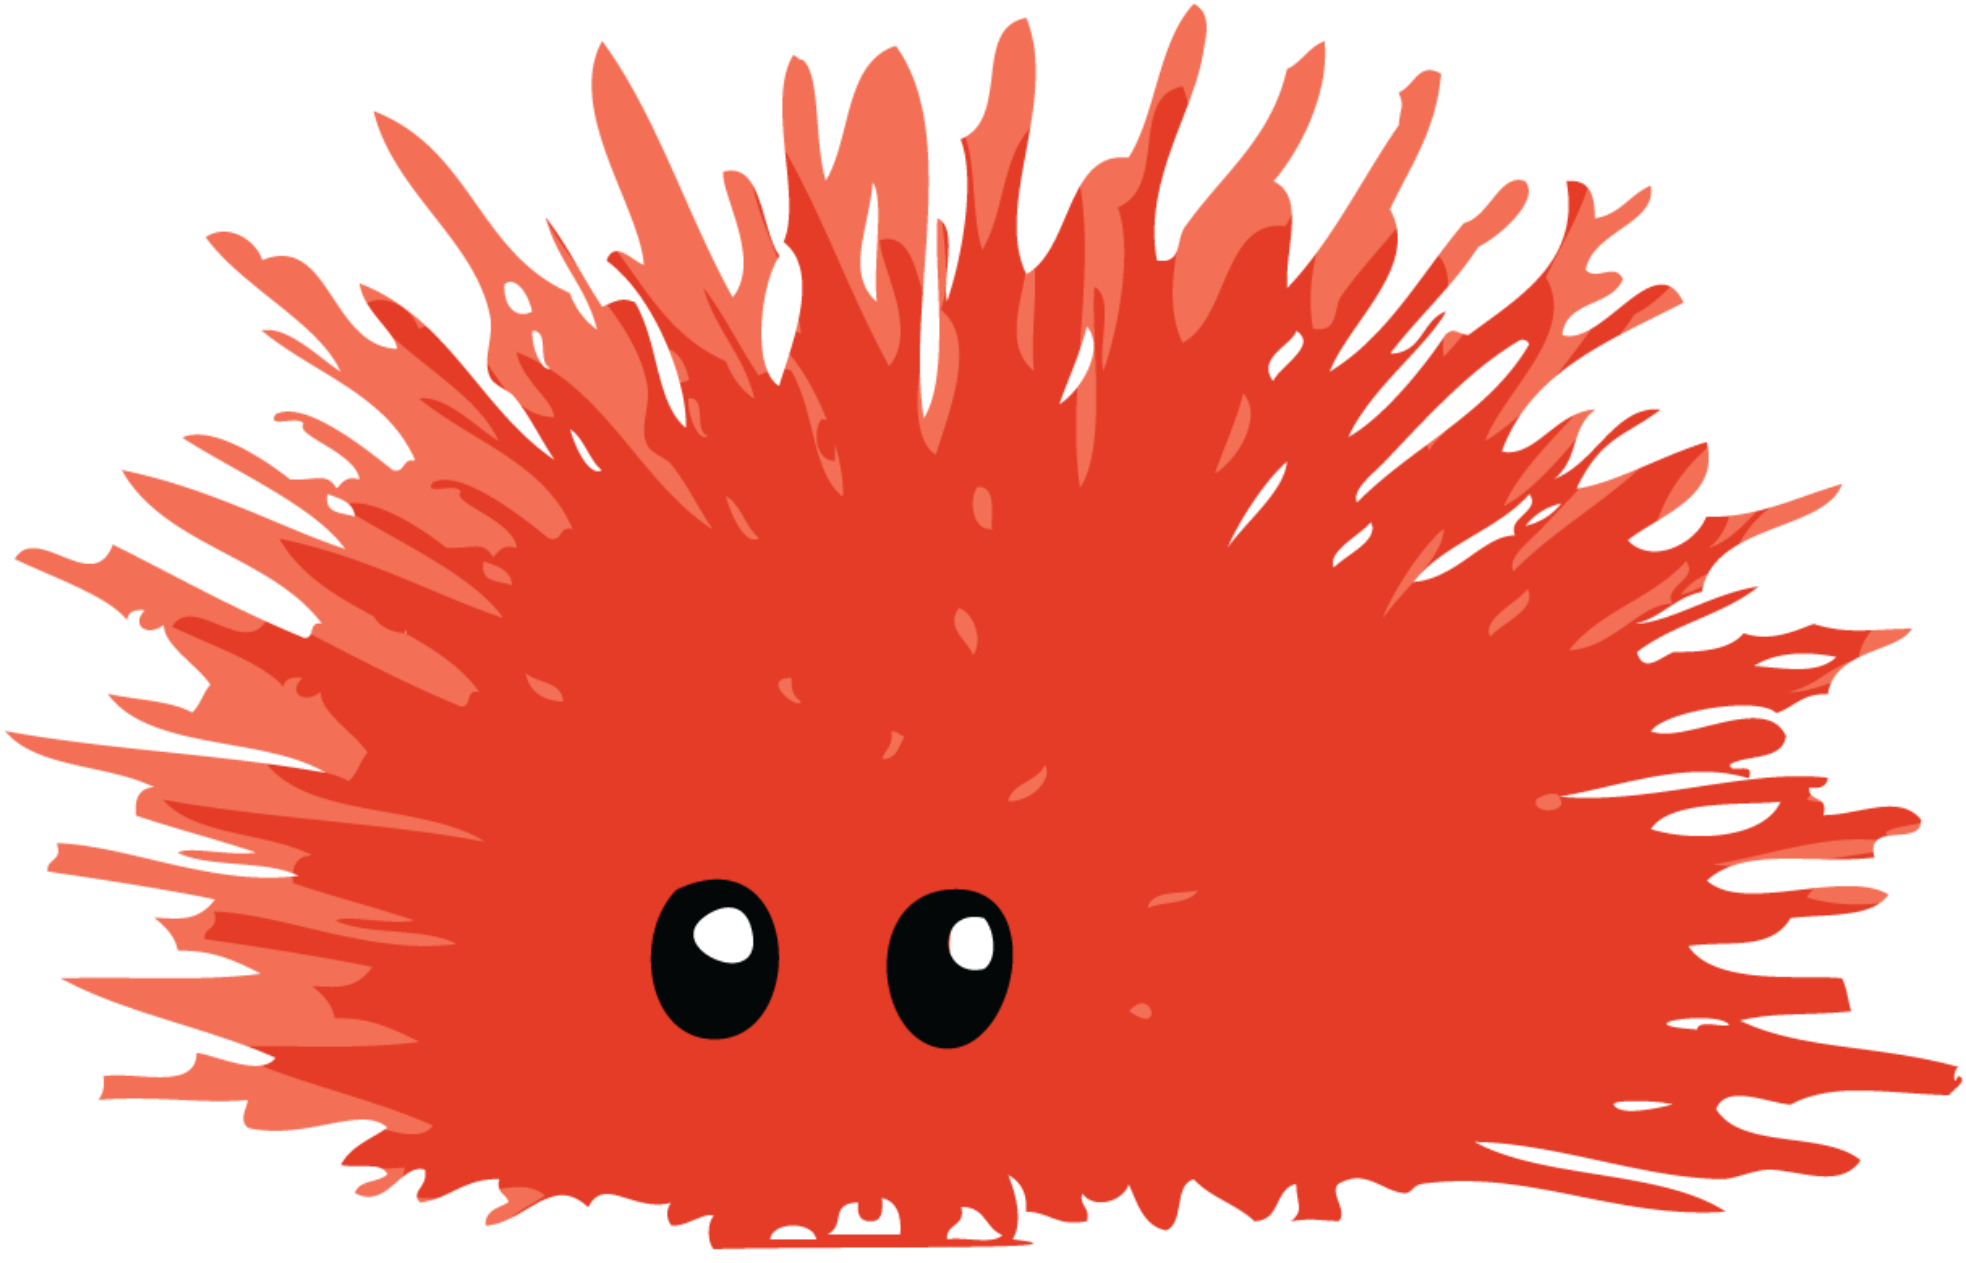

В любом языке нужны низкоуровневые, "системные" операции:

- взаимодействие с OS
- управление памятью
- быстрые коллекции

Где Живёт Интересный Код?

- в runtime языка (Go) / C-расширениях (Python)

Нужно убедится, что расширение:

1. даёт правильный результат при правильном использовании
2. даёт ошибку при неправильном использовании (нет UB)

- написан на самом языке (C/C++)

Язык должен быть достаточно низкоуровневым, сложно отделить "runtime" от бизнесс-логики

Rust

В Rust **`unsafe`** выполняет роль C-расширений

Ядро языка:

- `*const T`, `*mut T` (разыменовывание — **`unsafe`**)
- **`extern "C" fn`** `malloc(usize);` (вызов — **`unsafe`**)
- `&T`, `&mut T`, move semantics, alias analysis

Стандартная библиотека:

- `Box`, `Vec`, `HashMap`
- `stdio`, `println!`

Rust

`unsafe` это "эффект": **`unsafe`** операцию можно выполнить только из **`unsafe`** функции

Внутри safe функции можно написать **`unsafe`** блок, но нужно гарантировать, что не возникнет UB

https://journal.stuffwithstuff.com/2015/02/01/what-color-is-your-function/

unsafe операции

1. разыменование сырого указателя
2. вызов **`unsafe`** функции
3. **`impl`** для **`unsafe trait`**
4. доступ к **`static mut`**
5. доступ к полям **`union`**

UB

1. разыменование висящего/нулевого указателя
2. чтение не инициализированной памяти
3. нарушение правил алиасинга (создание перекрывающихся `&mut`)
4. создание невалидных примитивных значений: нулевые/висящие ссылки, нулевые указатели на функцию, `bool` отличный от 0 или 1, невалидный вариант `enum` , невалидный `char` (например, одиночный суррогат), не UTF-8 `str`
5. разматывание стэка через FFI
6. гонка данных

Центральное Обещание Rust

Используя систему типов, можно писать safe функции, вызывающие внутри `unsafe` операции, но **гарантирующие** отсутствие UB для любых значений параметров

`unsafe` это не инструмент выхода за пределы языка, это основание!

Пример

```
fn get_pair_mut<T>(
    xs: &mut [T],
    idx1: usize,
    idx2: usize,
) -> (&mut T, &mut T)
```

Функция `get_pair_mut` принимает массив, пару индексов и возвращает уникальные ссылки на соответсвующие элементы

Пример

```rust
fn get_pair_mut<T>(
    xs: &mut [T],
    idx1: usize,
    idx2: usize,
) -> (&mut T, &mut T) {

    let x1: *mut T = &mut xs[idx1];
    let x2: *mut T = &mut xs[idx2];

    unsafe {
        assert!(idx1 != idx2);
        (&mut *x1, &mut *x2)
    }
}
```

Вызов `get_pair_mut` с **любыми** `idx1` и `idx2` не может вызвать UB (но может привести к панике)

Пример

```rust
/// Safety:
/// idx1 and idx2 must not be equal
unsafe fn get_pair_mut<T>(
    xs: &mut [T],
    idx1: usize,
    idx2: usize,
) -> (&mut T, &mut T) {

    let x1: *mut T = &mut xs[idx1];
    let x2: *mut T = &mut xs[idx2];

    (&mut *x1, &mut *x2)
}
```

`assert` убрать можно, но тогда мы **обязаны** пометить функцию как **`unsafe`**

Пример

```
fn get_pair_mut<T>(
    xs: &mut [T],
    idx1: usize,
    idx2: usize,
) -> (&mut T, &mut T) {
    let (idx1, idx2) = (idx1.min(idx2), idx1.max(idx2));
    let (lo, hi) = xs.split_at_mut(idx2);
    (&mut lo[idx1], &mut hi[0])
}
```

Написав одну функцию с **`unsafe`** (**`split_at_mut`**), другие можно выразить через неё, и получить memory safety бесплатно

Параметризованные функции

```
impl<T> [T] {
    fn sort(&mut self)
    where
        T: Ord,
}
```

Функция `sort` может использовать **`unsafe`** внутри (например, чтобы убрать проверку выхода за границу массива)

Для любых `T`, `sort` должна гарантировать отсутствие UB (потому что не помечена **`unsafe`**)

Даже если реализация `T: Ord` не корректна (например, нет транзитивности), UB возникнуть не должно!

Параметризованные функции

Для сравнения, В C++ вызов `std::sort` для типа с не-транзитивным `<` это UB (и может привести к выходу за границу массива на практике)

Баг в `<=>` в modern C++ может привести к UB: весь код `unsafe`

В Rust **`unsafe`** позволяет установить **границы** возможного UB

Параметризованные функции

Возможные альтернативы:

```
impl<T> [T] {
    /// Safety:
    /// Ord must be a correct total order for T
    unsafe fn sort_faster(&mut self)
    where
        T: Ord,
}
```

Проверка контракта — задача вызывающего `sort_faster`

Параметризованные функции

Возможные альтернативы:

```
/// Safety:
/// Implementors guarantee that Ord is a correct total order
unsafe trait TrustedOrd: Ord {}

impl<T> [T] {
    fn sort_faster(&mut self)
    where
        T: TrustedOrd,
}
```

Проверка контракта — задача автора типа `T`

Send & Sync

Send и Sync — интересные **`unsafe trait`**

Автор **`unsafe impl`** `Sync` **`for`** `T` обязан гарантировать отсутствие гонок данных

В большинстве случаев автор — компилятор

Если все компоненты типа `Sync`, то сам тип тривиально `Sync`

Напишем std

Show Me the Code

https://github.com/rust-lang/rust/blob/bfb443eb1de484fde141fa9090a9f4291cbe60a5/

Нас будет интересовать `src/libcore`

[T]

libcore/slice/mod.rs:

```
#[repr(C)]
struct FatPtr<T> {
    data: *const T,
    len: usize,
}
```

FatPtr — представление &[T] в runtime: пара из указателя и длины

`[T]`

`libcore/slice/mod.rs`:

```
#[repr(C)]
union Repr<'a, T: 'a> {
    rust: &'a [T],
    rust_mut: &'a mut [T],
    raw: FatPtr<T>,
}
```

C-style, **`unsafe`** union: содержит одно из полей, без тэга

Доступ к полю **`union`** — **`unsafe`** операция

Изначально исключительно для FFI, но нашёл применение в **`unsafe`** коде

В данном случае: способ получить `FatPtr<T>` из `&T`

[T]

```rust
#[repr(C)]
union Repr<'a, T: 'a> {
    rust: &'a [T],
    rust_mut: &'a mut [T],
    raw: FatPtr<T>,
}

impl<T> [T] {
    pub const fn len(&self) -> usize {
        unsafe {
            Repr { rust: self }  (1)
                .raw             (2)
                .len
        }
}
```

(1) скоструировали `Repr` из `[T]`

(2) получили `FatPtr<T>`

```rust
use std::mem::{size_of, align_of};

pub unsafe fn from_raw_parts<'a, T>(
    data: *const T,
    len: usize,
) -> &'a [T] {
    debug_assert!(
        data as usize % align_of::<T>() == 0,
        "attempt to create unaligned slice",
    );
    debug_assert!(
        size_of::<T>().saturating_mul(len) <= isize::MAX as usize,
        "attempt to create slice covering half the address space",
    );
    Repr { raw: FatPtr { data, len } }.rust
}
```

Констуктор слайсов: сделали `FatPtr<T>`, посмотрели как на `&[T]`

`[T]`

Немного компиляторной магии для синтаксиса `[T]`, в остальном библиотечный код

Представление — `repr(C)` структура

Каст между `&[T]` и `FatPtr<T>` через **`union`**

Знаем, что слайсы представленны как `FatPtr<T>`, потому что так работают `from_raw_parts` и `from_raw_parts_mut`

[T]

```rust
impl<T> [T] {
    pub const fn as_ptr(&self) -> *const T {
        self as *const [T] as *const T (1)
    }
}
```

(1) получить указатель можно без **unsafe** (тоже магия компилятора)!

[T]

```rust
pub fn get<I: SliceIndex<Self>>(&self, index: I)
    -> Option<&I::Output>
{
    index.get(self)
}

pub fn get_mut<I: SliceIndex<Self>>(&mut self, index: I)
    -> Option<&mut I::Output>
{
    index.get_mut(self)
}
```

Индексация — через вспомогательный трейт `SliceIndex`, чтобы работали `.get(0)` и `.get(0..10)`

```rust
impl<T> SliceIndex<[T]> for usize {
    type Output = T;
    fn get(self, slice: &[T]) -> Option<&T> {
        if self < slice.len() {
            unsafe { Some(self.get_unchecked(slice)) }
        } else {
            None
        }
    }
    unsafe fn get_unchecked(self, slice: &[T]) -> &T {
        &*slice.as_ptr().add(self)
    }
}

impl<T: ?Sized> *const T {
    pub unsafe fn add(self, count: usize) -> Self where T: Sized
}
```

`<*const T>::add` **unsafe** — указатель должен быть in-bounds

```rust
impl<T> SliceIndex<[T]> for ops::Range<usize> {
    type Output = [T];

    fn get(self, slice: &[T]) -> Option<&[T]> {
        if self.start > self.end || self.end > slice.len() {
            None
        } else {
            unsafe { Some(self.get_unchecked(slice)) }
        }
    }

    unsafe fn get_unchecked(self, slice: &[T]) -> &[T] {
        from_raw_parts(
            slice.as_ptr().add(self.start),
            self.end - self.start,
        )
    }
}
```

split_at_mut

```
pub fn split_at_mut(&mut self, mid: usize) -> (&mut [T], &mut [T]) {
    let len = self.len();
    let ptr = self.as_mut_ptr();

    unsafe {
        assert!(mid <= len);

        (from_raw_parts_mut(ptr, mid),
         from_raw_parts_mut(ptr.add(mid), len - mid))
    }
}
```

assert необходим!

IterMut

```rust
pub struct IterMut<'a, T: 'a>(&'a mut[T]);

impl<'a, T> Iterator for IterMut<'a, T> {
    type Item = &'a mut T; (1)

    fn next(&mut self) -> Option<&'a mut T> {

        if self.0.is_empty() { return None; }

        let (l, r) = self.0.split_at_mut(1);
        self.0 = r;
        l.get_mut(0)
    }
}
```

(1) Магия! Повторные вызовы `next` гарантируют непересекающиеся `&mut` ссылки

IterMut

```rust
pub struct IterMut<'a, T: 'a>(&'a mut[T]);

impl<'a, T> Iterator for IterMut<'a, T> {
    type Item = &'a mut T;

    fn next(&mut self) -> Option<&'a mut T> {

        if self.0.is_empty() { return None; }

        let (l, r) = self.0.split_at_mut(1); (1)
        self.0 = r;
        l.get_mut(0)
    }
}
```

(1) reborrowing, потому что не можем сделать move из поля `&mut` значения :-(

swap trick

```rust
pub struct IterMut<'a, T: 'a>(&'a mut[T]);

impl<'a, T> Iterator for IterMut<'a, T> {
    type Item = &'a mut T;

    fn next(&mut self) -> Option<&'a mut T> {
        let slice = std::mem::replace(&mut self.0, &mut []);
        if slice.is_empty() { return None; }

        let (l, r) = slice.split_at_mut(1);
        self.0 = r;
        l.get_mut(0)
    }
}
```

swap trick

В реальности `IterMut` устроен по другому — как пара указателей

```rust
struct IterMut<'a, T> { // unused type parameter
    begin: *mut T,
    end: *mut T,
}
```

Variance

Subtyping

В Rust есть отношение "быть подтипом" на временах жизни:

```
'a: 'b
```

Читается как `'a` outlives `'b`

`&'a T` это подтип `&'b T` — сокращение вж не нарушает memory safety

```rust
fn min<'a>(xs: &Vec<'a str>, default: &'a str) -> &'a str {
    ...
}

fn main() {
    let xs: Vec<'static str> = vec!["hello", "world"];
    let local: String = "spam".to_string()
    let m = min(&xs, local.as_str())
}
```

Из `Vec<&'static str>` и `&'a str` можно выбрать `&'a str`

Так как `&'static str <: &'a str`

то `Vec<'static str> <: Vec<'a str>`

`Vec<T>` ковариантен по `T`

```rust
fn assign_ref<'a>(r: &mut &'a str, s: &'a str) {
    *r = s
}

fn evil(r: &mut &'static str) {
    let local: String = "spam".to_string();
    let local: &str = local.as_str();
    assign_ref(r, local)
}

fn main() {
    let mut hello: &'static str = "hello";
    evil(&mut hello);
    println!("{}", hello);
}
```

```rust
fn assign_ref<'a>(r: &mut &'a str, s: &'a str) {
    *r = s
}

fn evil(r: &mut &'static str) {
    let local: String = "spam".to_string();
    let local: &str = local.as_str();
    assign_ref(r, local)
}

fn main() {
    let mut hello: &'static str = "hello";
    evil(&mut hello);
    println!("{}", hello);
}
```

`&'a mut T` инвариантна по `T`

`T`	ковариантность
`&'a T`	ковариантность по `'a` и `T`
`&'a mut T`	ковариантность по `'a`, инвариатность по `T`
`*const T`	ковариантность
`*mut T`	инвариантность
`fn(T)`	**контр**вариантность
`fn() -> T`	ковариантность
`fn(T) -> T`	инвариантность
`Cell<&'a T>`	инвариантность

Единственная разница между `*const T` и `*mut T` — variance

И `&'a T`, и `&'a mut T` ковариантны по `'a`

PhantomData

```
struct S<'a, T> {
    ...
}
```

Как определить вариантность по `'a` и **T**?

PhantomData

```rust
struct S<'a, T> {
    xs: &'a mut Vec<T>,
}
```

Как определить вариантность по `'a` и `T`?

Автоматически, из определения `S`

PhantomData

Если параметр типа не используется, то нельзя определить вариантность ⇒ все параметры должны использоваться

`PhantomData<T>`

Магический ZST тип, который ведёт себя как `T` с точки зрения variance и dropcheck

```rust
struct A<'a, T> {
    value: T,
    r: &'a ()
}
```

```rust
struct B<'a, T> {
    value: &'a T,
}
```

`A` вызывает деструктор `T`, `B` нет

```rust
use std::marker::PhantomData;

struct IterMut<'a, T> {
    begin: *mut T,
    end: *mut T,
    slice: PhantomData<&'a mut [T]>,
}

impl<'a, T> IterMut<'a, T> {
    fn new(slice: &'a mut [T]) -> Self {
        assert!(std::mem::size_of::<T>() > 0);
        let begin = slice as *mut [T] as *mut T;
        let end = unsafe { begin.add(slice.len()) };
        IterMut {
            begin,
            end,
            slice: PhantomData,
        }
    }
}
```

```rust
impl<'a, T> Iterator for IterMut<'a, T> {
    type Item = &'a mut T;

    fn next(&mut self) -> Option<&'a mut T> {
        if self.begin == self.end {
            return None;
        }
        let curr = self.begin;
        unsafe {
            self.begin = self.begin.add(1);
            Some(&mut *curr)
        }
    }
}
```

NonNull<T>

Для написания структур данных часто нужен ковариантный указатель, из которого удобно получать `&mut T`

`std::ptr::NonNull<T>` — как раз такой тип

```
size_of::<Option<NonNull<T>>>()
    == size_of::<NonNull<T>>()
```

```rust
#[rustc_layout_scalar_valid_range_start(1)]
pub struct NonNull<T: ?Sized> {
    pointer: *const T,
}
impl<T: ?Sized> NonNull<T> {
    pub const unsafe fn new_unchecked(ptr: *mut T) -> Self {
        NonNull { pointer: ptr as _ }
    }
    pub fn new(ptr: *mut T) -> Option<Self> {
        if !ptr.is_null() {
            Some(unsafe { Self::new_unchecked(ptr) })
        } else {
            None
        }
    }
    pub const fn as_ptr(self) -> *mut T {
        self.pointer as *mut T
    }
    pub unsafe fn as_mut(&mut self) -> &mut T {
        &mut *self.as_ptr()
    }
}
```